

# AhorraGo

|                            |                          |                           |                               |                            |
|----------------------------|--------------------------|---------------------------|-------------------------------|----------------------------|
| <b>31,124</b><br>Productos | <b>31,139</b><br>Precios | <b>3</b><br>Supermercados | <b>502</b><br>Cambios Fase 5B | <b>40</b><br>Tests passing |
|----------------------------|--------------------------|---------------------------|-------------------------------|----------------------------|

# 1. Estado Real de la Base de Datos

Datos verificados directamente sobre la BD SQLite post-aplicación de Fase 5B. Ningún número proviene de estimaciones — todos fueron consultados en tiempo real.

| Métrica                 | Valor  | Observación                                |
|-------------------------|--------|--------------------------------------------|
| Productos totales       | 31,124 | Sin cambios desde Fase 5B                  |
| Precios totales         | 31,139 | ~1 precio por producto (baja equivalencia) |
| producto_base únicos    | 27,286 | Muy alto — indica escaso matching          |
| Grupos con equivalencia | 2,621  | Solo 8.4% de producto_bases agrupados      |
| Sin producto_base       | 0      | Todos los productos tienen base asignada   |
| Supermercados           | 3      | Jumbo · Líder · Unimarc                    |

## Distribución por Categoría

| Categoría                    | Productos | % del total                          |
|------------------------------|-----------|--------------------------------------|
| Lácteos, Huevos y Congelados | 5,658     | 18.2%                                |
| Desayuno y Snacks            | 4,802     | 15.4%                                |
| Bebidas                      | 4,274     | 13.7%                                |
| Despensa                     | 3,998     | 12.8%                                |
| Higiene Personal             | 2,839     | 9.1%                                 |
| Carnes y Pescados            | 2,060     | 6.6%                                 |
| Congelados                   | 1,960     | 6.3%                                 |
| Limpieza                     | 1,640     | 5.3%                                 |
| Bebé                         | 1,471     | 4.7%                                 |
| Frutas y Verduras            | 998       | 3.2%                                 |
| Panadería                    | 808       | 2.6%                                 |
| Mascotas                     | 432       | 1.4%                                 |
| Lácteos (sin tilde) ■        | 184       | 0.6% — categoría duplicada, anomalía |

■ Anomalía detectada: existe una categoría duplicada 'Lacteos, Huevos y Congelados' (sin tilde) con 184 productos. Probablemente residuo de scraping con encoding diferente. Estos productos tienen visibilidad reducida para el usuario final.

## 2. Estado de Fases Completadas

| Fase    | Objetivo                                               | Modo      | Estado      |
|---------|--------------------------------------------------------|-----------|-------------|
| Fase 1  | Seguridad crítica (API key, paginación, URLs, índices) | REAL      | ■ Completa  |
| Fase 2  | Refactor: normalizacion.py, matching.py, Pydantic v2   | REAL      | ■ Completa  |
| Fase 3  | Matching avanzado: RapidFuzz + score 0-100 + atributos | REAL      | ■ Completa  |
| Fase 4  | Diagnóstico: conflictos, métricas, reportes CSV/MD     | DRY RUN   | ■ Completa  |
| Fase 5A | Simulación mejora en 5 categorías objetivo             | DRY RUN   | ■ Completa  |
| Fase 5B | Aplicación real: Mascotas + Limpieza (502 cambios)     | REAL      | ■ Completa* |
| Fase 5C | Aplicación: Bebidas + Higiene Personal + Bebé          | PENDIENTE | ■ Próxima   |

\* Fase 5B completada con bug de datos identificado (ver Sección 4). 95% de los 502 cambios son correctos. Requiere corrección quirúrgica antes de Fase 5C.

### Resultados Fase 5B — Métricas verificadas

| Métrica                                     | Antes | Después | Δ             |
|---------------------------------------------|-------|---------|---------------|
| Equivalencias totales (Mascotas + Limpieza) | 698   | 924     | +226 (+32.4%) |
| Conflictos totales (Mascotas + Limpieza)    | 234   | 163     | -71 (-30.3%)  |
| Equivalencias Limpieza                      | 451   | 632     | +181 (+40.1%) |
| Conflictos Limpieza                         | 166   | 133     | -33 (-19.9%)  |
| Equivalencias Mascotas                      | 247   | 292     | +45 (+18.2%)  |
| Conflictos Mascotas                         | 68    | 30      | -38 (-55.9%)  |

### 3. Arquitectura y Algoritmo de Matching

#### Módulos del sistema

| Módulo                      | Responsabilidad                                                                          |
|-----------------------------|------------------------------------------------------------------------------------------|
| app/normalizacion.py        | normalizar_texto, detectar_familia, extraer_atributos, normalizar_formato, MARCAS_CONOCI |
| app/matching.py             | candidato_compatible (filtros duros) + matching_score (0-100 con RapidFuzz)              |
| app/matching_diagnostics.py | resumen_matching, metricas_por_categoria, diagnosticar_matching                          |
| app/fase5a_rules.py         | Reglas específicas por categoría: atributos_fase5a, key_fase5a, compatible_fase5a        |
| app/fase5b_apply.py         | Workflow completo: backup → seleccionar → aplicar → validar                              |
| app/url_utils.py            | generar_url_busqueda con urllib.parse.urlencode                                          |
| app/services.py             | buscar_opciones_producto, comparar_lista, calcular_ahorro                                |
| app/main.py                 | Endpoints FastAPI, configuración CORS, orquestación                                      |

#### Algoritmo de Matching — Desglose del Score (0-100)

El score combina filtros duros (candidato\_compatible) que rechazan inmediatamente si alguna condición falla, y un score numérico ponderado con RapidFuzz para los candidatos que superan los filtros duros. Umbral global: 68 pts. Umbral Fase 5A/5C: 82 pts.

| Componente          | Pts máx | Condición                                            |
|---------------------|---------|------------------------------------------------------|
| Marca               | 20      | Coincidencia exacta normalizada                      |
| Volumen / Peso      | 15      | Misma medida en ml o g                               |
| Producto_base       | 15      | Coincidencia exacta o $\text{RapidFuzz} \times 0.08$ |
| Categoría (familia) | 10      | Misma familia detectada                              |
| Cantidad (pack)     | 10      | Mismo número de unidades                             |
| Tokens              | 10      | Intersección/Unión de tokens útiles                  |
| Similitud textual   | 20      | $\text{RapidFuzz token\_set\_ratio} \times 0.20$     |
| Formato             | 5       | Formato normalizado coincide                         |
| TOTAL               | 100     | Umbral mínimo: 68 pts (global) / 82 pts (Fase 5C)    |

## 4. Bug Crítico Confirmado en Fase 5B

■ **BUG VERIFICADO EN BASE DE DATOS REAL — Requiere corrección antes de Fase 5C**

### Descripción del problema

25 productos de tipo Fideo/Pasta alimenticia están mislabeledados como **Limpieza > Blanqueadores** en la base de datos. Esto es un error de scraping histórico ocurrido durante la importación original de datos desde Lider/Jumbo/Unimarc. El algoritmo de Fase 5B funcionó **correctamente** dado los datos disponibles: detectó que estos fideos eran similares entre sí (mismo formato/peso) y los agrupó dentro de la categoría Limpieza, donde estaban catalogados.

### Ejemplos verificados en BD

| ID   | Producto                                    | Categoría en BD | Subcategoría en BD | producto_base asignado |
|------|---------------------------------------------|-----------------|--------------------|------------------------|
| 386  | Fideo Pasta Al Huevo Farfalle 400g Talli    | Limpieza        | Blanqueadores      | limpieza_400_g         |
| 387  | Fideo Pasta Al Huevo Rigati 400g Talli      | Limpieza        | Blanqueadores      | limpieza_400_g         |
| 3525 | Fideo Pasta Multigrano Espiral Fusilli 350g | Limpieza        | Blanqueadores      | limpieza_350_g         |
| 3529 | Fideo Pasta Multigrano Spaghetti N°5 350g   | Limpieza        | Blanqueadores      | limpieza_350_g         |
| 3475 | Fideo Pasta Espirales N°49 400g Carozzi     | Limpieza        | Blanqueadores      | limpieza_carozzi_400_g |

### Impacto real cuantificado

| Métrica                                          | Valor                                            |
|--------------------------------------------------|--------------------------------------------------|
| Total cambios Fase 5B                            | 502                                              |
| Cambios afectados por datos incorrectos (fideos) | 25 (5.0%)                                        |
| Cambios correctos                                | 477 (95.0%)                                      |
| Categoría incorrecta en BD (causa raíz)          | Scraping error — Limpieza > Blanqueadores        |
| Backup disponible para rollback                  | backups/supercheck_pre_fase5b_20260531_215846.db |

### Acción recomendada

■ **NO ejecutar rollback completo. El 95% de los cambios son correctos y revertirlos sería contraproducente. La acción correcta es un fix quirúrgico:**

1. Crear script fix/reclasificar-fideos-limpieza.py
2. Corregir categoria\_id de los 25 productos → Despensa
3. Revertir producto\_base de esos 25 IDs al valor anterior
4. Generar CSV de trazabilidad del fix
5. Agregar test de regresión: 0 alimentos en Limpieza > Blanqueadores
6. Ejecutar suite de 40 tests para confirmar sin regresiones

**Esfuerzo estimado: 2-3 horas de desarrollo + 30 minutos de validación manual.**

## 5. Calidad de Código — Hallazgos

| Severidad | Módulo                       | Hallazgo                                                                                     | Acción                            |
|-----------|------------------------------|----------------------------------------------------------------------------------------------|-----------------------------------|
| BAJO      | normalizacion.py             | MARCAS_CONOCIDAS tiene entradas duplicadas sin tilde (ej. 'Pavanes 2, n.º Cascano' × 2). Las | Revisar y eliminar duplicados.    |
| BAJO      | main.py L1                   | BOM UTF-8 al inicio del archivo (▀). No rompe Python pero genera BOM en git diff.            | Eliminar BOM.                     |
| BAJO      | matching_diagnostics.py L168 | Myes168 de score_promedio limitado a 80 grupos sobre 2,624 (3%). Mín(500, total_grupos)      | Revisar lógica de limitación.     |
| BAJO      | matching.py L173             | Umbral global 68 hardcodeado. Dificulta calibración por categoría.                           | Reorganizar por categoría.        |
| MEDIO     | BD SQLite                    | Categoría duplicada 'Lácteos' (con/sin tilde): 184 productos. No se visibiliza en los datos  | Mejorar visibilidad de los datos. |

### Lo que está bien — Fortalezas del código

- Modularización correcta: cada módulo tiene una responsabilidad única y clara
- Matching con filtros duros + score numérico: arquitectura robusta y auditable
- Pydantic v2 correctamente migrado (@field\_validator + @classmethod)
- Queries optimizadas: yield\_per(500), GROUP BY en SQL, índices aplicados
- Paginación en todos los endpoints de búsqueda (limit/offset validados)
- URLs generadas con urllib.parse.urlencode — soporte correcto de caracteres especiales
- Backup automático + trazabilidad CSV + rollback disponible

## 6. Cobertura de Tests

Estado actual: 40 tests passing. Tiempo de ejecución: 0.78s.

| Archivo                   | Tests | Qué cubre                                                        |
|---------------------------|-------|------------------------------------------------------------------|
| test_phase1.py            | 5     | Paginación, URLs con tildes, lock de archivo                     |
| test_matching_score.py    | 7     | Extracción de atributos, score alto/bajo, sabores incompatibles  |
| test_matching.py          | 3     | Equivalencias: 1L=1000ml, 1.5L=1500ml, pack6=x6                  |
| test_fase5a_rules.py      | 5     | Reglas por categoría: Bebidas, Limpieza, Higiene, Bebé, Mascotas |
| test_fase5b_apply.py      | 9     | Apply, rollback, idempotencia, exclusión de grupos riesgosos     |
| test_integration.py       | 4     | Endpoints HTTP con BD SQLite en memoria                          |
| test_fase4_diagnostico.py | 4     | Clasificación de conflictos, métricas por categoría              |
| test_fixtures_matching.py | 2     | 22 pares de productos reales (fixtures JSON)                     |
| test_auditoria_datos.py   | 1     | Auditoría general de datos                                       |
| TOTAL                     | 40    | 100% passing — 0.78s                                             |

### Brechas de testing detectadas

| Brecha                                              | Riesgo | Acción recomendada                          |
|-----------------------------------------------------|--------|---------------------------------------------|
| No hay test para /productos/resumen-compra          | MEDIO  | Agregar test de endpoint crítico de negocio |
| No hay test de regresión para alimentos en Limpieza | ALTO   | Agregar como parte del fix quirúrgico       |
| No hay test para categoría duplicada 'Lácteos'      | MEDIO  | Agregar en limpieza de datos                |
| test_fixtures_matching.py solo valida 2 escenarios  | BAJO   | Expandir con más pares reales               |
| Sin test E2E de flujo completo usuario              | BAJO   | Diferir a cuando haya usuarios beta         |

## 7. Matriz de Riesgos

| Riesgo                                   | Severidad | Probabilidad | Estado      | Acción                              |
|------------------------------------------|-----------|--------------|-------------|-------------------------------------|
| 25 fideos mislabeled en BD               | ALTO      | CONFIRMADO   | Activo      | Fix quirúrgico inmediato            |
| Categoría duplicada 'Lácteos' (1M prods) | MEDIO     | CONFIRMADO   | Activo      | Merge en próxima iteración          |
| 1,601 conflictos en producto_base prodal | BAJO      | CONFIRMADO   | Gestionado  | Mejora progresiva por fases         |
| MARCAS_CONOCIDAS sin tildes (duplicados) | BAJO      | CONFIRMADO   | Activo      | Fix en 15 min                       |
| Muestreo score_promedio al 3% (802621)   | BAJO      | CONFIRMADO   | Activo      | Aumentar límite                     |
| BOM en main.py                           | MUY BAJO  | CONFIRMADO   | Activo      | Fix cosmético                       |
| SQLite — escalabilidad                   | BAJO      | FUTURO       | Monitoreado | Migrar a PostgreSQL si > 100K prods |
| Sin usuarios aún — no hay feedback real  | BAJO      | PRESENTE     | Esperado    | Lanzar beta tras Fase 5C            |



## 8. ¿Es Fase 5C la Decisión Correcta?

### Veredicto: Sí — con un prerequisite obligatorio

Las reglas para Bebidas, Higiene Personal y Bebé ya existen y fueron validadas en simulación DRY RUN (Fase 5A). La infraestructura de backup + rollback está probada. Las mejoras proyectadas son alcanzables. El único riesgo es heredar productos mislabeled en estas categorías si no se resuelve el bug antes.

### Mejoras proyectadas para Fase 5C (datos de simulación)

| Categoría        | Productos | Equiv. actuales | Equiv. proyectadas | Mejora |
|------------------|-----------|-----------------|--------------------|--------|
| Bebidas          | 4,274     | ~28%            | ~40%               | +40.6% |
| Higiene Personal | 2,839     | ~23%            | ~37%               | +59.1% |
| Bebé             | 1,471     | ~24%            | ~38%               | +59.2% |

### Plan técnico detallado para Fase 5C

#### Prerequisite (antes de Fase 5C)

1. Fix quirúrgico: reclasificar 25 fideos mislabeled
2. Fix MARCAS\_CONOCIDAS: restaurar variantes con tilde
3. Test de regresión: 0 alimentos en Limpieza > Blanqueadores
4. Commit en feature/fix-datos-pre-fase5c

#### Etapas 1 — Auditoría de datos en categorías objetivo

1. Detectar productos mislabeled en Bebidas, Higiene Personal, Bebé
2. Usar misma herramienta que detectó los fideos
3. Validar que distribución de subcategorías es coherente

#### Etapas 2 — Simulación DRY RUN

1. Ejecutar `simular_mejora_matching_fase5a.py` para las 3 categorías
2. Revisar `fase5a_falsos_positivos.csv` generado
3. Muestra manual de 20 cambios propuestos por categoría
4. Criterio de go/no-go: falsos positivos < 2% del total propuesto

#### Etapas 3 — Aplicación controlada

1. backup automático → seleccionar\_cambios → escribir CSV → aplicar (batch 100)
2. Solo si simulación aprueba criterio de go/no-go
3. Commit en feature/fase5c-matching

#### Etapas 4 — Validación post-aplicación

1. Endpoint `/diagnostico/matching` antes/después
2. Revisión manual de muestra de 20 cambios por categoría
3. Confirmar 40 tests passing + nuevos tests de Fase 5C
4. Generar `reports/FASE_5C_REPORTE.md`

**Categorías bloqueadas — NO tocar en ninguna fase: Frutas y Verduras · Congelados · Panadería · Carnes y Pescados · Desayuno y Snacks (alta variabilidad, revisión manual previa requerida)**

## 9. Recomendaciones y Conclusión

### Prioridades inmediatas (orden obligatorio)

| # | Tarea                                                   | Esfuerzo | Impacto                                        |
|---|---------------------------------------------------------|----------|------------------------------------------------|
| 1 | Fix quirúrgico: reclasificar 25 fideos + test regresión | 2-3 h    | ALTO — limpia datos Fase 5B                    |
| 2 | Fix MARCAS_CONOCIDAS: restaurar tildes                  | 15 min   | BAJO — mejora detección de marca               |
| 3 | Fix BOM en main.py + aumentar muestreo score_producto   | 15 min   | MUY BAJO — cosmético                           |
| 4 | Auditoría de datos en Bebidas / Higiene / Bebé          | 1-2 h    | ALTO — prerequisite Fase 5C                    |
| 5 | Fase 5C — Simulación DRY RUN                            | 2-3 h    | ALTO — mejora matching +40-59%                 |
| 6 | Fase 5C — Aplicación controlada                         | 1-2 h    | ALTO — con aprobación de simulación            |
| 7 | Fix categoría duplicada 'Lácteos'                       | 1 h      | MEDIO — 184 productos con visibilidad reducida |

### Estado de madurez del sistema

| Dimensión              | Rating    | Justificación                                                    |
|------------------------|-----------|------------------------------------------------------------------|
| Arquitectura de código | ★★★★■ 4/5 | Modularización limpia; falta parametrización de umbrales         |
| Precisión del matching | ★★★★■ 4/5 | Robusto en categorías objetivo; débil en Frutas/Carnes/Panadería |
| Calidad de datos       | ★★■■■ 2/5 | 80.3% sin equivalencia; 1,601 conflictos; 25 mislabeled          |
| Cobertura de tests     | ★★★★■ 4/5 | 40 tests, falta test E2E y regresión de datos                    |
| Documentación          | ★★★★★ 5/5 | Reportes completos por fase con métricas antes/después           |
| Seguridad de datos     | ★★★★★ 5/5 | Backup + rollback + trazabilidad CSV en todas las fases          |

### Conclusión

El sistema AhorraGo tiene una arquitectura sólida y un proceso de mejora de datos bien diseñado. Las fases 1-5B entregaron resultados reales y verificables. La deuda técnica es manejable y no bloquea el avance. El único bloqueador real para Fase 5C es el fix de los 25 fideos mislabeled, que representa 2-3 horas de trabajo con bajo riesgo.

Con el fix aplicado, Fase 5C puede ejecutarse con la misma infraestructura ya probada y aportar +40-59% de mejora en equivalencias para Bebidas, Higiene Personal y Bebé — las tres categorías con mayor volumen de productos después de Lácteos y Desayuno.