

Fase 5I - Pipeline Hardening

Fase 5I - Pipeline Hardening

Fecha: 2026-06-01

Objetivo

Corregir scrapers e importadores para impedir categorias imposibles antes de llegar a la BD.

Modo

- No se modifiko la BD existente.
- No se recargo la base.
- No se ejecuto scraping masivo.
- No se corrigieron productos existentes.
- No se recalculo producto_base.
- No se toco frontend.

Cambios Implementados

Se creo app/category_validator.py como barrera semantica compartida para el pipeline.

El validador:

- Detecta incompatibilidades semanticas entre nombre, categoria y subcategoria.
- Rechaza categorias imposibles.
- Sugiere categoria/subcategoria esperada.
- Registra rechazos en reports/pipeline_category_rejections.csv cuando el pipeline se ejecuta.
- Evita falsos positivos conocidos como Hair Food/Aguacate, Trocitos Jugosos en Mascotas y Pasta Limpiado

Integracion en Pipeline

- app/scrapper_lider.py: filtra productos antes de guardarlos en lider_real.csv.
- app/scrapper_jumbo_real.py: filtra productos antes de guardarlos en jumbo_real.csv.
- app/scrapper_unimarc.py: filtra productos antes de guardarlos en unimarc_real.csv.
- app/combinar_supermercados.py: filtra filas fuente antes de consolidar productos_supermercados.csv.
- app/importar_csv.py: ultima barrera antes de crear/actualizar productos en SQLite.

Reglas Cubiertas

- Bebidas en Bebe.
- Snacks/frutos secos en Bebe.
- Limpieza en Bebe.
- Mascotas fuera de Mascotas.
- Higiene Personal fuera de Higiene Personal.
- Limpieza fuera de Limpieza.
- Bebidas fuera de Bebidas.

Tests de Regresion

Se agregaron pruebas para:

- NotMilk.
- Coca-Cola.
- Yogu Yogu.
- Master Dog.
- Champion Dog.
- Pedigree.
- Nivea.
- Rexona.
- Dove.

Tambien se validan falsos positivos:

- Hair Food/Aguacate.
- Trocitos Jugosos en Mascotas.
- Pasta Limpiadora/Pink Stuff en Limpieza.

Estimacion Read Only

Sobre reports/fase5f_clasificacion_masiva.csv:

- Hallazgos Fase 5F: 1986.
- Hallazgos que bloquearia el validador: 1934.
- Remanente estimado post-hardening: 52.
- Objetivo solicitado: menos de 300 hallazgos.
- Resultado esperado: cumple el objetivo.

Sobre data/productos_supermercados.csv:

- Filas actuales: 34481.
- Filas que el validador rechazaria: 2949.
- Filas aceptadas estimadas: 31532.

Causa Raiz Atacada

Fase 5H identifico scraper_categoria_por_busqueda_amplia.

Fase 5I reduce ese riesgo colocando la barrera en cinco puntos:

1. Scraper Lider.
2. Scraper Jumbo.
3. Scraper Unimarc.
4. Combinador de CSV.
5. Importador a SQLite.

Riesgos

- Puede rechazar productos validos con nombres ambiguos si coinciden con marcas o palabras fuertes.
- El umbral de 52 hallazgos es estimado sobre reportes actuales; debe confirmarse con una recarga paralela.
- Los rechazos reducen cantidad de productos cargados si no se reemplazan por una categoria corregida.
- Antes de produccion conviene revisar reports/pipeline_category_rejections.csv luego de una corrida real

Recomendacion

Ejecutar Fase 5J como reload test post-hardening:

- No reemplazar todavia supercheck.db.
- Crear una nueva BD paralela.
- Ejecutar pipeline local con validadores activos.
- Confirmar que los hallazgos bajan de 300.
- Revisar rechazos antes de decidir si se corrige o descarta cada fila.

Validacion Ejecutada

- `python -m pytest tests/test_fase5i_category_validator.py -q`: OK.
- Medicion read-only sobre reportes y CSV actuales: OK.

Archivos

- `app/category_validator.py`
- `tests/test_fase5i_category_validator.py`
- `reports/FASE_5I_PIPELINE_HARDENING.md`
- `reports/FASE_5I_PIPELINE_HARDENING.pdf`