

Fase 5J-R — Fix del Validador de Categorías (pre-reload)

Fecha: 2026-06-02 **Autor:** Principal Engineer + Data Architect **Modo:** Prototipo validado sobre datos reales en disco. Sin scraping. Sin escritura a BD productiva.

Objetivo

Corregir `app/category_validator.py` **antes** de cualquier reload, porque el reload convierte cada rechazo del validador en un borrado permanente. Se detectaron falsos positivos por coincidencia de substring que provocaban pérdida de productos válidos.

Causa raíz de los falsos positivos (v1)

1. **Coincidencia por substring crudo.** keyword in texto hacía que jugo matcheara jugoso, caju matcheara cajun, etc.
2. **Palabras legítimas que contienen un keyword.** "Vinagre de **Vino**", "Carne al **Vino**", "**Bebida Láctea**" caían en la regla de bebidas.
3. **Sin vía de cuarentena.** Confianza Media eliminaba el producto igual que Alta: un falso positivo = pérdida de dato, silenciosa.
4. **Comparación de categoría sensible a acentos.** `cat == "Bebe"` fallaba con "Bebé"; convivían "Lácteos..." y "Lacteos..." como categorías distintas.

Cambios aplicados (v2)

- Coincidencia por **palabra completa** (regex `\b...\b`).
- **Exclusiones** para la regla de bebidas: vinagre, en vino, al vino, bebida lactea, saborizante, polvo, salsa.
- **Política de cuarentena:** confianza **Alta** → **reject** (se quita del load); confianza **Media** → **review** (se **conserva** y se registra en `pipeline_category_quarantine.csv` para revisión humana). Nunca se pierde un producto por confianza media.
- **Categoría insensible a acentos** (normalize aplicado a categoria).

Resultado medido (33.267 productos reales: Líder 7.536, Jumbo 23.794, Unimarc 1.937)

Métrica	v1 (substring)	v2 (word-boundary + cuarentena)
Productos borrados a la fuerza	1.440	999 (solo Alta)
Conservados y marcados (cuarentena)	0	287
Falsos positivos eliminados (ya ni se marcan)	—	154
Productos rescatados de borrado	—	441

Verificación dirigida

Falsos positivos que v1 borraba y v2 conserva: Vinagre de Vino Blanco, Base Maggi Jugoso, Carne Asada en Vino Tinto, Bebida Láctea Soprole Kéfir.

Aciertos reales (bug 5H) que v2 sigue rechazando con Alta: Pedigree en Carnes, Crema Nivea en Crema, Limpiador Cif en Crema, Whiskas Gato en Crema.

Tests

tests/test_category_validator.py — **16/16 PASSED**. Cubre: regresión de falsos positivos, word-boundary (jugoso, cajun), aciertos del bug 5H, insensibilidad a acentos, y la política de cuarentena (Media se conserva, sólo Alta devuelve False).

Rollback

El archivo nuevo reemplaza app/category_validator.py en la rama fase-5j-hardening. Rollback = `git checkout fase-5j-hardening -- app/category_validator.py` desde el commit anterior, o `git revert` del commit del fix. La versión v1 queda en el historial.

Pendiente (siguiente paso, no incluido en este fix)

- Modo *reprocess-only* en `reload_v3_fase5jr.py` (stages 2→5 sobre CSV en disco, sin `run_scrapers`) para producir `supercheck_reload_v3.db` real y medir el remanente.
- Normalizar acentos de categoria en `importar_csv.py` / `combinar_supermercados.py` para evitar categorías duplicadas en la BD.
- Fix del checkpoint de scrapers (marca "complete" aún con errores).